



26/20/2022

RB Informatics;

كلية الهندسة المعلوماتية
السنة الرابعة - الذكاء الصناعي

مقدمة في الشبكات العصبونية

د. ياسر خضرا

محتوى مجاني غير مخصص للبيع التجاري

الشبكات العصبونية





أعزائنا الطلاب، يسرنا أن نقدم لكم محاضرات مادة الشبكات العصبونية ونود التنويه إلى أن المرجع الرئيسي للمادة هو محاضرات الدكتور ياسر خضرا وهذا المحتوى داعم وشارح لها بالأمثلة التي تم ذكرها.

الذكاء الصناعي Artificial Intelligence

هو علم محاكاة الذكاء البشري من خلال تصنيف إما خوارزميات برمجية (software) أو (hardware) نمذجة للذكاء، وهو علم واسع جداً أساسه رياضي يعتمد على كيفية فهم قواعد عمل دماغ الإنسان وإسقاطها على منتج له علاقة بتنظيم الكمبيوتر ويجعله قادراً على التعلم والاستنتاج ورد الفعل على أوضاع لم تبرمج عليها الآلة.

من مجالات الذكاء الصناعي:

1. Natural language processing (NLP) معالجة اللغات الطبيعية: وهي مجال علوم الحاسوب واللغويات المعنية بالتفاعلات بين الحاسوب واللغات الطبيعية، أبسط مثال هو كيفية تفسير كلام الإنسان وتحويله من كلام منطوق إلى كلام مكتوب أو بالعكس تحويل النص المكتوب إلى نص منطوق، وما يتلوه من مراحل مثل: تحليل الكلام واكتشاف أنماط موجودة بالكلام والتعرف على الأشخاص من الكلام.... والكثير من التفاصيل المتعلقة بهذا المجال.
2. Automatic programming البرمجة الآلية
3. Robotics: كلمة روبوت لا تعني فقط الروبوت الذي يشبه الإنسان، بل للروبوت أشكال مختلفة، فالذراع الروبوتية الموجودة بالمعمل تدعى روبوت، والسيارة ذاتية القيادة تسمى روبوت، إذاً كلمة روبوت واسعة جداً فأي شيء ذاتي القيادة ينفذ مهمات مؤتمتة نسميه روبوت.



محتوى مجاني غير مخصص للبيع التجاري

الشبكات العصبونية Neural Networks

- هي محاكاة لآلية نقل السيالة العصبية إلى الدماغ أي هي محاكاة للدماغ المتحكم بجسم الإنسان، فهي تساعد على اتخاذ قرار، حل مشكلات، القيام بعمليات تصنيف وتنبؤ وتعرّف... إذاً بنية الشبكة العصبية عندما تحاكي الدماغ بعملها فهي تحاكي وظائفه.
- الشبكات العصبونية تقنية تستخدم لتحقيق أهداف machine learning.
- هناك شبكات عصبونية بطبقة واحدة أي: دخل - معالجة - خرج، وهناك شبكات عصبونية بطبقات متعددة أي: طبقة دخل - عدة طبقات داخلية للمعالجة - طبقة خرج (ويمكن أن يكون الخرج وحيد أو متعدد).
- إذا كان هناك عدة طبقات داخلية وأصبح هناك عمق للشبكة سُميت بالشبكات العميقة وتنتج عنها ما يسمى deep learning.

العصبون:

- هو وحدة النقل العصبي بالدماغ وبشكل أدق كل الأعصاب هي عصبونات متصلة مع بعضها البعض.
- يتكون العصبون من جسم واستطالة ومشابك، وتتم المعالجة داخله حسب تخصص العصبون.

■ ماذا نقصد بمحاكاة الدماغ؟!

- محاكاة الدماغ هي البحث عن بنية شبيهة ببنية الدماغ أي نأخذ الآلية التي يتعلم بها الإنسان ونطبقها على الآلة، أن نفكر كيف يعالج الإنسان المعلومات ويتطور مع الأيام، كيف يتعلم الدماغ وكيف تتخزن المعرفة وكيف يتحسن الأداء بالتدريب، أن نفهم بنية الدماغ...

- يوجد في الآلات العديد من الحساسات (المجسات)، والتي تحاكي الحواس الموجودة عند الإنسان، فعندما نتكلم عن وجود كاميرا في الآلة كأننا نقوم بمحاكاة الإحساس بالرؤية، حيث أنّ وظيفة هذه الحساسات هي نقل الظاهرة الفيزيائية إلى إشارة كهربائية.
- إن ميزة الإنسان الأساسية هي القدرة على التعلم والتطور، ومن هنا بدأت فكرة الذكاء الاصطناعي، وذلك عن طريق الشبكات العصبونية، حيث تحاكي هذه الشبكات نقل السيالة العصبية عن طريق العصبونات، وتأتي أهمية هذه الشبكات بكافة مكوناتها بسبب قدرتها على التصنيف، البحث، التنبؤ.

- تُعد الرياضيات حامل الشبكات العصبونية (هي حامل جميع العلوم أيضاً).

- أمثلة بسيطة على استخدام الرياضيات:
- الصورة هي مصفوفة ثنائية البعد، فعند القيام بعملية قلب للصورة فإننا في الحقيقة نأخذ منقول (مقلوب) هذه المصفوفة.
- عند القيام بعملية تكبير للصورة، فإننا نقوم بتوسيع المصفوفة وإضافة (زرع) حقول (أعمدة وصفوف).

أبسط شكل لفهم الرياضيات التقليدية بمنطق الشبكات العصبونية:

لتكن لدينا المعادلة التالية $ax^2 + bx + c = 0$ ، هذه المعادلة تكافئ عصبون له مدخلين، الأول x^2 والثاني x ، وبوجود على المدخل الأول وزن اسمه a وعلى المدخل الثاني وزن اسمه b وفيما بينهم إشارة جمع، ويوجد أيضا عنصر إضافي c وهو يعبر عن الانزياح، وتتم المعالجة داخل العصبون لتعطي المخرج الموافق وليكن على سبيل المثال: 1 اذا كانت المعادلة قابلة للحل و 0 اذا كانت المعالجة غير قابلة للحل.

للاطلاق من الذكاء الصناعي إلى الشبكات العصبونية، لا بد من المرور بتعلم الآلة:

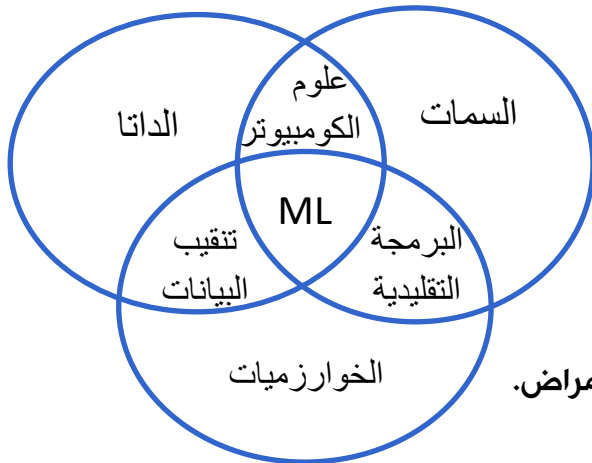
تعلم الآلة Machine Learning

بدأت الفكرة من كيف نستطيع أن نجعل الآلة تتعلم حيث التعلم هو الذي يؤدي إلى التطور، فتعلم الآلة هو دراسة فرع من العلوم التي تهتم بالأنماط الإحصائية.

- المرحلة الأولى: تطوير نماذج إحصائية ننتقل منها لاتخاذ قرار.
- المرحلة الثانية: بناء خوارزميات عن طريق جعل الكمبيوتر ينفذ مهام دون تعليمات خارجية، فهي تقوم على مبدأ أخذ الدخل والمخرج وإعطاء البرنامج على عكس البرمجة التقليدية.

تحتاج ML إلى ثلاثة أشياء أساسية:

1. Data (دخل ومخرج).
2. السمات (نستخلصها من الداتا) يجب أن تكون قابلة للقياس.
3. الخوارزميات (حيث يوجد خوارزميات خاصة بالتنبؤ وأخرى للتجميع...)



للتعلم ننتقل من داتا جزئية (غير مكتملة) للحصول على البرنامج (ليس المقصود هنا بالبرنامج الكود البرمجي وإنما model رياضي أي آلية التفكير التي نتنبأ أو نصنف وفقها وهو خطوة سابقة للكود) ثم تأتي حالات ليست داخل الداتا لنستطيع تصنيفها أو التنبؤ بها، مثال: التنبؤ بالأمراض.

الهدف الرئيسي من ML:

التعلم وتعميم تجربة التعليم انطلاقاً من الخبرات السابقة المكتسبة.

الفرق بين ML والبرمجة التقليدية:

في ML دخل الكمبيوتر هو الداتا والمخرج، والهدف هو الحصول على البرنامج، بينما يكون الدخل في البرمجة التقليدية هو الداتا والبرنامج، والهدف الحصول على المخرج.

أنواع Machine Learning:

1. Supervised learning:

- في هذا النوع يتم التعلم بوجود معلم، بمعنى آخر الانطلاق من معلومات معروفة ومن خرج معروف أي ثنائية (Input - Output) موجودة، والهدف هو تطوير آلية التعلم للمقدرة على التعرف.

- يتم استخدام **Labeled Data**، من تطبيقاته:

1. Regression:

قيم الخرج فيه مستمرة، يفيد في التنبؤ.

مثال: التنبؤ بسعر منزل وفقاً لمساحته وسعره.

2. Classification:

قيم الخرج فيه متقطعة، مثال: تصنيف الإيميل إلى spam و normal.



2. Unsupervised learning:

- في هذا النوع لا يوجد معلم أي أن الدخل معروف لكن الخرج غير معروف، والهدف ليس التصنيف إنما البحث في الداتا عن الانماط المشتركة لتجميع المشتركين مع بعضهم البعض.

- يتم استخدام **Unlabeled Data**، من تطبيقاته:

1. Dimensionality Reduction:

تخفيض عدد الأبعاد، مثلاً: تحويل دائرة ثنائية البعد إلى مستقيم أحادي البعد.

2. Clustering:

وهو تجميع الداتا إلى عدة أصناف.

3. Reinforcement Learning:

- في هذا النوع لا يكون التركيز على الداتا وإنما مراحل تنفيذ أو تطوير مسارات أو إجراءات جديدة.

- لا نهتم في هذا النوع كثيراً لأن الشبكات العصبونية تستخدم في النوعين الأول والثاني.

ملاحظة:

- نحصل على الداتا من البيانات الإحصائية، حيث تقسم الـ Dataset (مجموعة البيانات) إلى ثلاثة أقسام:
- Training data: وهو الجزء الذي تُدرَّب عليه المنظومة (الشبكة العصبونية أو أي نظام ذكاء صناعي).
- Validation data: للتأكد من صحة المعلومات.
- Testing data: للاختبار.
- طريقة تقسيم الداتا (أي نسبة كل قسم) متغيرة حسب حجم الداتا الموجودة.
- ملاحظة مهمة: الداتا الداخلة بالتدريب لا تدخل بالاختبارات، أي أن Input التدريب مختلف عن Input الاختبار.

Pattern

إن معظم عملنا بال Machin learning يتركز على السمات وإيجاد أنماط وهذه وظيفة الشبكة العصبونية، حيث تقوم بالتنبؤ بأنماط أو محاولة لإيجاد نمط يناسب متطلبات المشكلة التي نحاول حلها، حيث نحاول إيجاد أنماط في ال Data وهذا ما يسمى بال Data mining وهي تقوم بالبحث في كم هائل جداً من المعلومات لإيجاد نمط يصف هذه المعلومات وبالتالي القدرة على استخراج المفيد منها.

■ Pattern Recognition:

وهو مصطلح يعني التعرف على الأنماط أو تمييز النماذج، وبشكل أكثر دقة هو إعادة التعرف على الأنماط ذلك لأن النمط يكون معروف وهدفنا إعادة التعرف عليه بمكان آخر لم يتم التعرف عليه من قبل.

ما هو النمط ؟

- وهو عبارة عن غرض ما يتم اختصاره بمجموعة سمات تميزه عن غيره وتصف حالة ما أو شيء ما، مثال: نستطيع بشكل عام أن نصف الطالب الناجح بالجامعة بمجموعة صفات تميزه عن طالب من المتوقع أن يرسب، مثل أن يدرس الطالب محاضراته و يلتزم بحضورها ويحضر لامتحاناته فإننا نتوقع بأن هذا الطالب سينجح في النهاية، وبالتالي سنسمي هذه الصفات بنمط الطالب الناجح وإذا درسنا صفات الطلاب بهذا النمط ستكون لدينا القدرة على التوقع وليس التأكيد فيما إذا كان هذا الطالب ناجح أو لا.
- وكلما كانت الصفات الواصفة للنمط قابلة للقياس بدقة كانت دقة التوقع أكبر، فلو استخدمنا صفات قابلة للقياس مثل الوزن والطول واللون و... الخ فإن النتيجة ستكون دقيقة كونها مستندة لصفات دقيقة.

ML Applications


هناك العديد من الأنواع للأنماط وتستخدم في مجالات كثيرة مثل:

1. التعرف على الأصوات بمختلف أشكالها ومجالاتها، حيث أن الصوت ينقسم لعدة أنواع:

- Audio: الإنسان حين يتحدث يكون مجال الصوت بين ال 200 HZ إلى 4000 Hz تقريباً وهذا يختلف عن نطاق سمع الإنسان الذي يقع ضمن المجال 20 HZ إلى 20 KHZ وهذه المعطيات مفيدة في تحديد نطاق عملنا في تحديد الأصوات أو توليدها.
- Speech: وهو الكلام المنطوق كما تحدثنا عنه وهو الكلام المفهوم والذي نستطيع التعرف عليه.
- Voice: وهو تركيب المحارف ولكن ليس بالضرورة أن يكون قابل للتعرف أو أن يكون له معنى، وهذا ما يميزه عن ال speech.

مثال: ال Speech يكون عبارة عن نص مفهوم ويمكن للحاسوب التعرف عليه، أما ال Voice فهو جميع تركيب المحارف وليس بالضرورة أن يكون مفهوم مثل الهمهمة أو الصفير فهي تكون عبارة عن أحرف و لكن بشكل لا يعطي معنى.

Sound: وهو المصطلح الأعم والذي يجمع كل مصطلحات الصوت.



2. Handwriting recognition

- التعرف على الكلام المكتوب بخط اليد وتحويله لنص مكتوب بالكمبيوتر، وهو أداة مهمة جداً ومن استخداماتها:
- التعرف على اللغات المكتوبة بالنصوص الأثرية وإنشاء نسخ الكترونية منها مما يمكن من نشر هذه النصوص وإمكانية دراستها بشكل أوضح و أسهل.
- التعرف على التوقيعات في الشيكات البنكية مما يعطينا وسيلة حماية جيدة لاكتشاف الغش والتزوير.
- ولكن هذه العملية صعبة نوعاً ما لوجود لغات تعتمد على الرسم في كتابتها مثل اللغة العربية أو الصينية وغيرها من اللغات، فاللغة العربية مثلاً ممكن كتابة الكلمة بعدة أشكال حسب خط المستخدم و بالتالي حصول أخطاء في التعرف.
- ومن أحدث الطرق المستخدمة هي تقطيع الكلمة لعدة مقاطع وبالتالي التعرف على كل مقطع بشكل منفصل ولكن مازالت نسبة الخطأ عالية نوعاً ما.

3. Computer Vision:

وهو علم التعرف على الصور وإيجاد المعلومات واستخراجها من الصور، ويمكن ألا يكون التعرف عن طريق صورة وإنما عن طريق إشارات وحركات وهذا ما تستخدمه الشركات في تطوير البرمجيات أو الأدوات التي تساعد ذوي الاحتياجات الخاصة.

4. Biometric Recognition

وهي التعرف على الخصائص الحيوية كالبصمة أو القزحية أو الصوت.. الخ




5. Fingerprint Recognition:

وهو التعرف على البصمات عن طريق شكلها ونمطها حيث لكل إنسان بصمة مختلفة وتختلف بطول الخط وشكله وتقطعاته والعديد من الخصائص التي يهتم بها هذا المجال.


6. Medical Applications:

مثل التعرف على الأورام والتفاصيل الظاهرة بالصور الطبية ومحاولة تحديد فيما إذا كانت طبيعية أو ناتجة عن مرض أو بداية أعراض لمرض ما.

Skin Cancer Detection



Breast Cancer Detection



Pattern recognition Vs. Machine Learning

Machine Learning	Pattern recognition
بناء الخوارزميات لحل مشكلة التعرف على الأنماط، فهو يقوم بتحليل المعلومات الموجودة ومحاولة إيجاد حل للمشكلة وإيجاد طريق للتعرف على النمط عن طريق التعلم واستكشاف المعلومات الجديدة.	يستخدم خوارزميات ال Machine Learning لحل المشكلات المصممة لها و لكن يكون الحل المقدم له تحليلي رياضي و ليس بحاجة للتعلم و انما جاهز للاستخدام مباشرة دون تعلم.
تدريب الالة لجعلها قادرة على التعرف على الانماط واسقاطها على مشاكل معينة.	ليس بحاجة للتعلم و انما يستخدم للتعرف على النمط مباشرة .
و يتميز التعلم الآلي عن تمييز الأنماط بكونه يستطيع التعامل مع المعلومات الجديدة و التكيف معها و تحسين أدائه بناءً على المدخلات الجديدة و استنتاجاً من تجاربه السابقة	

وبالتالي نستنتج بأن تمييز الأنماط يستخدم خوارزميات التعلم الآلي في عمله ولكن من دون التعلم من الأنماط التي درسها.

Deep learning

وهو علم مشتق من التعلم الآلي ويستخدم عند وجود Data كبيرة جداً، ومفهوم ال Deep learning هو إنشاء شبكات عصبونية بعدد كبير من الطبقات وهذا سبب تسميتها بال Deep.

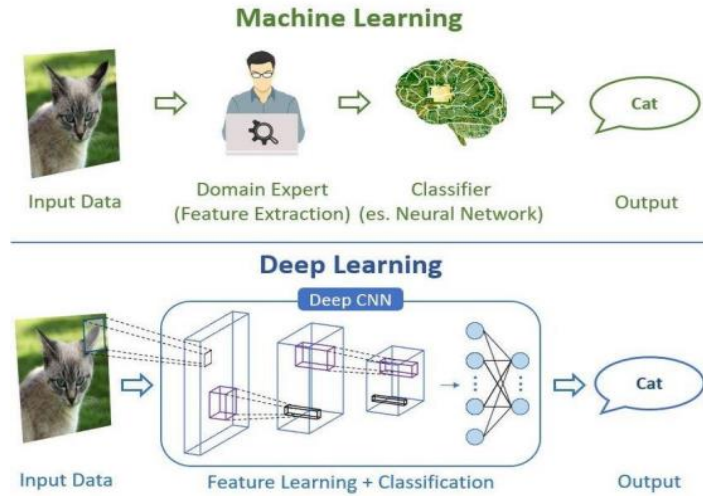
لماذا نلجأ لل Deep learning ؟

وذلك لأن الشبكة العصبونية بطبقات قليلة لم تكن قادرة على معالجة البيانات واستخراج المعلومات اللازمة والمرغوب بها.

مقارنة بين الشبكات العصبونية العادية والشبكات العصبونية العميقة:

Deep learning	Machine learning
تحتاج كميات كبيرة من ال Data لتدريبها	يمكن تدريبها ب Data قليلة
تقدم دقة عالية	تقدم دقة جيدة
تحتاج وقت كبير للتدريب	لا تحتاج الى وقت كبير للتدريب
تحتاج لل GPU للتدريب بسبب الحجم الهائل	يمكن أن يتم التدريب على المعالج
محاولة معالجة المشكلة بطرق متعددة	عدد محدود من الامكانيات على معالجة المشكلة

Machine Learning Vs. Deep Learning



مقارنة بين Pattern Recognition & Machine Learning & Deep Learning:

- Pattern Recognition: محاولة تمييز الأنماط من دون تعلم.
- Machine Learning: تقسيم الصفات ومحاولة معالجتها والقدرة على التعلم والقدرة على حفظ هذه الأنماط.
- Deep Learning: تقسيم الصفات لعدد أكبر من التعلم الآلي والقدرة على التعلم وحفظ هذه الأنماط.

Features

السمات وهي أي شيء قابل للقياس مثل الوزن والطول.. والخ، ويمكن جمعهم بما يسمى " شعاع السمات ":

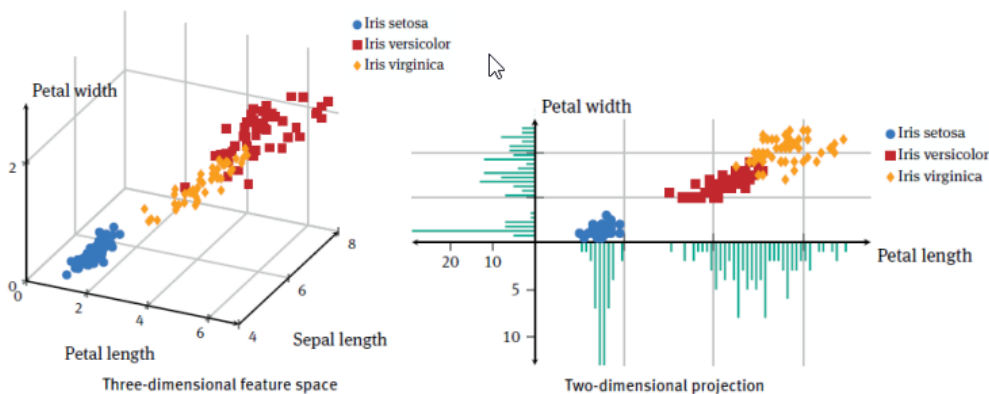
$$\begin{bmatrix} \text{height} \\ \text{weight} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{X}$$

Feature Vector




Feature Space:

يتم فيه تمثيل شعاع السمات ويكون بعده حسب عدد السمات.



Feature Extraction:

استخراج السمات يعني انتقاء السمات المناسبة من أجل بناء نتائج أقرب ما يمكن للصحة وهو عامل مهم في تحديد نتائج الآلة، مثال: إذا أردنا اختبار صحة مريض فلا يهمنا لون سيارته أو أسمه أو رقم هاتفه وإنما نبحث عن السمات التي ستفيدنا في مشكلتنا مثل العمر وفيما إذا كان مدخن أو يعاني من مرض وراثي. ويمكن اعتبار الصفات المختارة جيدة إذا انتجت لدي نتائج قابلة للفصل نوعاً ما.



مثال معروف لمسألة تصنيف (Classification):

مشكلة تحديد سمك السلمون عن سمك السيباس عن طريق صورة السمكة.

لدينا المعلومات الآتية:

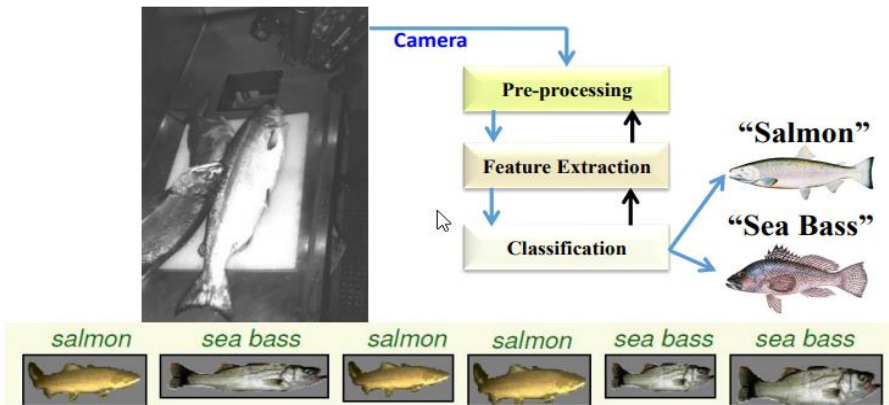
وهو أن سمك السلمون أغلى من سمك السيباس بكثير وبالتالي فإن الأخطاء التي تحدث تسبب خسارة مالية لصاحب المصنع، في حال عدم القدرة على تحديد نوع السمكة على الجهاز أن يحدد السمكة على أنها سمكة سلمون وذلك لتحقيق مصلحة المستهلك.

أولاً: علينا أن نحدد ما المعوقات التي ممكن أن تعرقل عمل الآلة خلال التصنيف، و في مثالنا قد يكون شدة الإضاءة أو توضع السمكة في خط الإنتاج أو ضجيج الكاميرا... الخ ، حيث أخذ هذه المعوقات وحلها سواء عن طريق حل برمجي أو حلها بالطرق التقليدية (كرفع شدة الإضاءة مثلاً).

ثانياً: وضع منهجية للعمل، ونتم بتحديد آلية عمل الآلة وما الخطوات التي ستتبعها للقيام بالتصنيف الصحيح، في مثالنا

من الممكن اتباع الخطوات التالية:

- أخذ صورة للسمكة
- عزل السمكة بالصورة
- استخلاص الصفات وتحديد
- اتخاذ قرار التصنيف



ثالثاً: نقوم بالمعالجة الأولية للصورة، وهي محاولة إظهار الصورة بشكل واضح لاستخراج الصفات منها بشكل دقيق قدر الإمكان.

رابعاً: بعد الحصول على عينات من صور الأسماك وتصنيفها يجب علينا تقسيم الداتا لداتا للتدريب وداتا اختبار، حيث تستخدم داتا التدريب في جعل الآلة قادرة على التصنيف واتخاذ القرار وداتا الاختبار أو التجريب في تجريب الآلة والتحقق من النتائج، بالطبع لن نقوم بالتجريب على عينات التدريب لأن الجهاز قد حفظها مسبقاً وإنما نحتاج لمعلومات جديدة وعينات جديدة للتجريب و بالتالي لا نستخدم مجموعة التدريب في الاختبار.

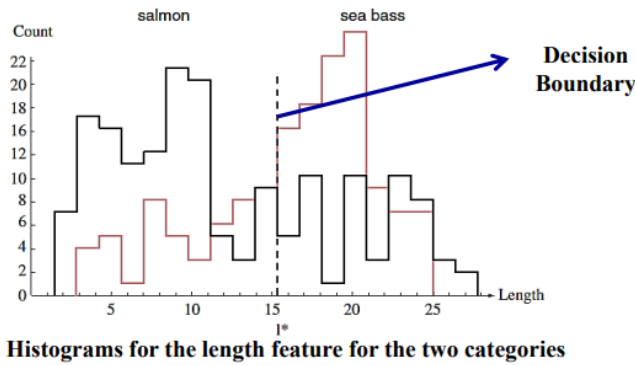
خامساً: اختيار السمات المناسبة التي سنقوم باتخاذ القرار على أساسها، وتختلف من مسألة لأخرى، ولذلك يجب أن تكون سمات مناسبة لمشكلتنا التي نحاول حلها، في مثالنا يمكن أن تكون:

- الطول
- البريق الصادر عن السمكة
- العرض
- عدد الزعانف وأشكالها
- مكان الفم

..الخ

يجب تحديد التحديات التي ستواجه الآلة عند اختيار هذه السمات، مثل تشابه طول بعض أسماك السلمون مع سمك السيباس.


استخراج الصفات:



في حال قمنا بالقياس على سمّة واحدة ولتكن الطول وقمنا برسم النتائج برسم بياني فإننا سنحصل على رسم بياني يبين نقاط سمك السلمون ونقاط سمك السيباس:

حيث الخط الأحمر هو سمك السيباس والخط الأسود هو سمك السلمون، ونلاحظ بأن الرسم البياني متداخل وغير قادرين على وضع خط يفصل النوعين بشكل تقريبي، وبالتالي نستنتج بأن صفة الطول غير مناسبة بشكل فعال لتحديد نوع السمك.

ولكن بأخذ صفة البريق الظاهر من السمكة



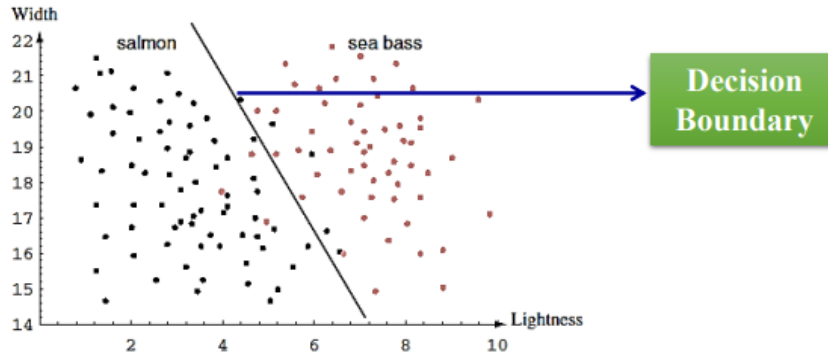
Histograms for the average lightness feature for the two categories



سنجد بأن الشكّلين تم عزلهم بشكل أفضل وهذا يعني بأن صفة البريق أفضل من صفة الطول في تحديد السمك.



Multiple Features:

كما لاحظنا سابقاً بأن صفة واحدة لم تكن جيدة كفاية لتحديد نوع السمك وفي هذه الحالات سنقوم باستخدام عدة صفات لتحديد النوع وبالتالي الحصول على نتائج أدق وأفضل.
 باستخدام صفة العرض والبريق في التحديد يمكن أن يعطينا تقسيم أفضل للنقاط وبالتالي نتائج توقع أدق.



Quality of Features:

وكما تحدثنا سابقاً فإن اختيار سمات منفصلة وغير متداخلة تحسن من عملية التصنيف.
 عند استخدام سمات معقدة وكثيرة لإنشاء التصنيف فإنه قد ينتج لدينا رسم بياني مفرط التعقيد وعند ازدياد كمية المعلومات سيصبح من الصعب عليه فرزهم بشكل صحيح وهذا ما يسمى بالـ **Overfitting**.
 وعلى عكس الـ **Overfitting**، فإنها عند استخدام سمات غير مهمة أو لا تحقق المطلوب سينتج لدينا خط بياني غير قادر على التصنيف بشكل جيد ويؤدي إلى التداخل وهذا ما يسمى بالـ **Underfitting**.



وبالتالي سيتوجب علينا الاعتدال للحصول على
أفضل النتائج وبدقة أكبر للمعلومات والعينات
الجديدة المستقبلية

التحديات والصعوبات التي ستواجهها اليوم

ستكون هي نفسها نقطة الانطلاق غداً.

انتهت المحاضرة...

