



9/11/2022



The ADALINE

د. ياسر خضرا


محتوى مجاني غير مخصص للبيع التجاري

الشبكات العصبية

Adaptive Linear Neuron

- رغم كفاءة الشبكات العصبية السابقة التي مررت معنا إلا أنها لم تكن تحل جميع المشاكل وهذا أدى إلى تطوير الشبكة العصبية بطريقة ال Adaline حيث تم تصميمها وتطويرها في السبعينيات وكانت من قبل مهندسي كهرباء، الذين استخدموها لحل بعض المشاكل التي واجهتهم، وقد أثبتوا بالتجربة العملية أنها فعالة وقابلة للعمل.

- يكون لها شكل الشبكة وبنية العصبون نفسه، ويكمّن الفرق بين الشبكة العصبية بطريقة ال Adaline والشبكات العصبية الأخرى في كون هذه الطريقة تحوي تابع اختبار بعد تابع التفعيل.



شكل العصبون بال Adaline :

و نلاحظ إضافة قسم ال error .

ويشتراك ال Adaline مع ال perceptron في كون قيم الخرج ثنائية وبالتالي هما طريقتان جيدتان للتصنيف الثنائي.

من أهم صفات طريقة ال Adaline :

تابع التفعيل :

تستخدم توابع التفعيل الثنائية، ومن أشهر توابع التفعيل الثنائية المستخدمة هما تابع Bipolar و Step .

Supervised

و تعني بأن الدخل والخرج معلومين و يتم استخدامهم لتدريب الشبكة.



قاعدة التعلم : Learning rule


وتستخدم قاعدة دلتا المعرفة بالشكل:

$$u = \sum_{i=1}^n w_i \cdot x_i - \theta \Leftrightarrow u = \sum_{i=0}^n w_i \cdot x_i$$

$$y = g(u)$$


من المهم معرفة تابع التفعيل المستخدم قبل البدء بالتدريب وذلك لمعرفة كيفية وصفالمشكلة بشكل يناسب التابع

لو استخدمنا تابع ال Step




فإن القيم ستكون محصورة بين ال 0 وال 1

أما لو استخدمنا تابع ال Bipolar



فإن القيم ستكون بين ال -1 و ال 1

وبالنسبة للقاعدة العامة فقد اعتبرنا أن الانزياح هو أحد المدخلات (x_0) وبالتالي تابع الجمع سيبدأ من الصفر (بعض المراجع يكون الانزياح موجود على تابع الجمع وبالتالي المجموع يبدأ من ال 1)



محتوى مجاني غير مخصص للبيع التجاري



ملاحظة مهمة:

P : هو عدد عينات التدريب¹

n : هو عدد الوصفات x_1

عدد عينات التدريب يعني كم مثال للاختبار و كل مثال اختبار يحوي n واصفة.

عملية تدريب ال Adaline

- دائمًا في خرج كل عملية تدريب يوجد نسبة خطأ يرمز له E ويعني الفرق بين القيمة المطلوبة والقيمة الناتجة، وكلما نتج خطأ فإن الشبكة بحاجة للتدريب.

- في طريقة ال perceptron لا يقبل الخطأ ولو بنسبة قليلة ويمكن اعتبار أن الخطأ موجود و لكن بقيمة 0. أما في الأدالين فإن الخطأ مقبول ولكن بنسبة صغيرة قدر الإمكان وتعطى معادلة الخطأ المقبولة بالشكل:

$$E(w^*) \leq E(w), \text{ for } \forall w \in R^{n+1}$$

إن التابع E تابع ل W وذلك لأن الدخل ثابت والخرج ثابت والذي يتغير هو w وبالتالي فإن الخطأ يقع في الأوزان.

(*) $E(w)$: قيمة الخطأ المثالية المطلوبة والمتواعدة

: $E(w)$ قيمة الخطأ الناتج بكل دورة

و بالتالي الخطأ يعتبر مقبول عندما تكون قيمة الخطأ أصغر أو تساوي القيمة المطلوبة.

ملاحظة: لا نستمر بتصغير قيمة الخطأ حتى نصل لأصغر قيمة قد يصل إليها التابع، حيث أن الاستمرار بتصغير القيمة يمكن أن يستنزف الكثير من الجهد وقيمة الخطأ تنقص بمقدار قليل وغير مقبول وبهذه الحاله تتوقف.

- يعرف $E(w)$ بالعلاقة:

$$E(w) = \frac{1}{2} \sum_{k=1}^p (d^{(k)} - u)^2$$

$$E(w) = \frac{1}{2} \sum_{k=1}^p \left(d^{(k)} - \left(\sum_{i=1}^n w_i \cdot x_i - \theta \right) \right)^2$$

$$E(w) = \frac{1}{2} \sum_{k=1}^p (d^{(k)} - (w^T \cdot x^{(k)} - \theta))^2$$

d_k : هي القيمة المتوقعة (المحسوبة).

u : هو التابع المعطى بالعلاقة:

$$\left(\sum_{i=0}^n w_i \cdot x_i - \theta \right)$$

ولكن: $\sum_{i=0}^n w_i \cdot x_i^{(k)}$ هي عملية ضرب مصفوفات حيث يمكن التعبير عنها بالشكل

معلومة رياضية:
 الرياضيات المستمرة هي تفاضل
 الرياضيات المتقطعة هي فرق
 والرياضيات المستخدمة في الشبكات العصبية هي الرياضيات المتقطعة، لأنه كمثال لا نستطيع
 تحقيق التكامل بالبرمجة، إنما نقوم بالتقسيط والجمع.

- نقوم باشتقةق تابع الخطأ بالنسبة للأوزان:

$$\nabla E(w) = \frac{\partial E(w)}{\partial w}$$

ونسمى هذا التفاضل لتابع الخطأ بالتلدرج.

وتعني العلاقة بأننا نحسب تأثر تغير تابع الخطأ بتغير الوزن w والذي نسعى لتصغيره قدر الإمكان.

- وباشتقاق العلاقة:

$$E(w) = \frac{1}{2} \sum_{k=1}^p (d^{(k)} - (w^T \cdot x^{(k)} - \theta))^2$$

ينتج التابع:

$$\nabla E(w) = \sum_{k=1}^p (d^{(k)} - (w^T \cdot x^{(k)} - \theta)) \cdot (-x^{(k)})$$

$$\nabla E(w) = \sum_{k=1}^p (d^{(k)} - u) \cdot x^{(k)}$$

ولكن:

$$\Delta w = -\eta \cdot \nabla E(w) \Rightarrow \Delta w = \eta \sum_{k=1}^p (d^{(k)} - u) \cdot x^{(k)}$$

وهو الشكل النهائي للعلاقة، وبالتالي فإن معادلة تحديث الأوزان هي من الشكل:

$$w^{current} = w^{previous} + \eta \cdot (d^{(k)} - u) x^{(k)}, \quad \text{with } k = 1 \dots p$$

حيث أن η يسمى عامل التعلم وهو يحدد سرعة العملية ويكون عادة محصور بين الـ 0 و 1
 فلو كان صغير جداً فإن القفزة ستكون صغيرة ولو كان كبير القفزة ستكون كبيرة، ولذلك علينا اختيار قيمة مناسبة له.

Delta learning rule

$$w \leftarrow w + \eta \cdot (d^{(k)} - u) \cdot x^{(k)}, \quad \text{with } k = 1 \dots p,$$


Weights
 ↓
 w
 ↓
 k^{th} desired output
 ↓
 $d^{(k)}$
 ↓
 Learning rate
 $0 < \eta < 1$
 ↑
 u
 ↑
 k^{th} training sample
 ↓
 $x^{(k)}$
 Output Value

W : مصفوفة الأوزان

$\chi^{(k)}$: مصفوفة الدخل

U : القيمة الناتجة من التابع

η : عامل التعلم



كما هو موضح بالصورة فإن عملية التدريب تستمر حتى الوصول للقيمة الصغرى وتختلف سرعتها بحسب عامل التعلم كما تكلمنا سابقاً، وتتوقف عندما ينحدر التدرج للصفر ونقبل الخطأ بنسبة معينة حسب حدود الخطأ المحددة

$$|\bar{E}(w^{current}) - \bar{E}(w^{previous})| \leq \epsilon$$

خطوات تطبيق الـ Adaline بالقاعدة دلتا:



- الحصول على مجموعات التدريب
- الحصول على القيم المطلوبة وربط كل قيمة مع عينة التدريب الموافقة
- تعريف مصفوفة الأوزان W بقيم عشوائية صغيرة
- تعريف قيمة عامل التعلم η و تعريف الحد لقيمة الخطأ ϵ
- تعريف عدد حقب التدريب epoch
- تكرار: $< 6.1 > \bar{E} W^{previous} \leftarrow \bar{E}(w)$



وتعني اسناد القيمة الجديدة للخطأ الناتجة عن حقبة التدريب لقيمة الخطأ السابقة
ثم نقوم بالمرور على جميع عينات التدريب وتعديل الأوزان

< 6.2 > For all training samples $\{x^{(k)}, d^{(k)}\}$, do:

$$< 6.2.1 > u \leftarrow w^T \cdot x^{(k)};$$

$$< 6.2.2 > w \leftarrow w + \eta(d^{(k)} - u) \cdot x^{(k)};$$

نزيد عدد الحقبة:

< 6.3 > epoch \leftarrow epoch + 1

بعدها نقوم بحساب تابع الخطأ بالأوزان الجديدة واسنادها للخطأ الحالي

< 6.4 > $\bar{E}^{current} \leftarrow \bar{E}(w)$

بالعلاقة:

$$\bar{E}(w) = \frac{1}{p} \sum_{k=1}^p (d^{(k)} - u)^2$$

وهي ما تسمى MSE (Mean Squared Error) وتكون بالطريقة التالية:

Begin {MSE Algorithm}

{<1> Obtain the number of training samples {p};
<2> Initialize variable \bar{E} with zero value $\{\bar{E} \leftarrow 0\}$;
<3> For all training inputs $\{x^{(k)}, d^{(k)}\}$, do:
 <3.1> $u \leftarrow w^T \cdot x^{(k)}$;
 <3.1> $\bar{E} \leftarrow \bar{E} + (d^{(k)} - u)^2$;
 <4> $\bar{E} \leftarrow \frac{\bar{E}}{p}$;

Begin {MSE Algorithm}

والهدف منها هو إيجاد قيمة الخطأ الجديدة وحساب الفرق بينها وبين القيمة القديمة للخطأ وذلك لمعرفة أن كان هناك داعي للاستمرار (قيمة الخطأ غير مقبولة) أو التوقف (قيمة الخطأ لا يمكن أن تكون أصغر أو قيمة نقصان الخطأ صغيرة) ونلاحظ أن الفرق بالقيمة المطلقة حيث أننا لا نهتم بالقيمة وإنما بالفرق بين قيمة الخطأ السابق وقيمة الخطأ الجديد.

Until: $|\bar{E}(w^{current}) - \bar{E}(w^{previos})| \leq \epsilon$





وبالتالي الشكل النهائي للخوارزمية:

Begin {ADALINE Algorithm – Training Phase}

- <1> Obtain the training sample set $\{\mathbf{x}^{(k)}\}$;
- <2> Associate the desired output $\{d^{(k)}\}$ for each obtained sample;
- <3> Initialize the vector \mathbf{w} with small random values;
- <4> Specify the learning rate $\{\eta\}$ and the required precision $\{\varepsilon\}$;
- <5> Initialize the epoch counter $\{\text{epoch} \leftarrow 0\}$;
- <6> Repeat:
 - <6.1> $\bar{E}^{\text{previous}} \leftarrow \bar{E}(\mathbf{w})$;
 - <6.2> For all training samples $\{\mathbf{x}^{(k)}, d^{(k)}\}$, do:
 - <6.2.1> $u \leftarrow \mathbf{w}^T \cdot \mathbf{x}^{(k)}$;
 - <6.2.2> $\mathbf{w} \leftarrow \mathbf{w} + \eta \cdot (d^{(k)} - u) \cdot \mathbf{x}^{(k)}$;
 - <6.3> $\text{epoch} \leftarrow \text{epoch} + 1$;
 - <6.4> $\bar{E}^{\text{current}} \leftarrow \bar{E}(\mathbf{w})$;
- Until: $|\bar{E}^{\text{current}} - \bar{E}^{\text{previous}}| \leq \varepsilon$

End {ADALINE Algorithm – Training Phase}


وبهذه الطريقة استطعنا إيجاد الأوزان التي تحقق أصغر نسبة خطأ.

مثال: شبكة للفرز الثنائي:

Begin {ADALINE Algorithm – Training Phase}


- <1> Obtain the training sample set $\{\mathbf{x}^{(k)}\}$;
- <2> Associate the desired output $\{d^{(k)}\}$ for each obtained sample;
- <3> Initialize the vector \mathbf{w} with small random values;
- <4> Specify the learning rate $\{\eta\}$ and the required precision $\{\varepsilon\}$;
- <5> Initialize the epoch counter $\{\text{epoch} \leftarrow 0\}$;
- <6> Repeat:
 - <6.1> $\bar{E}^{\text{previous}} \leftarrow \bar{E}(\mathbf{w})$;
 - <6.2> For all training samples $\{\mathbf{x}^{(k)}, d^{(k)}\}$, do:
 - <6.2.1> $u \leftarrow \mathbf{w}^T \cdot \mathbf{x}^{(k)}$;
 - <6.2.2> $\mathbf{w} \leftarrow \mathbf{w} + \eta \cdot (d^{(k)} - u) \cdot \mathbf{x}^{(k)}$;
 - <6.3> $\text{epoch} \leftarrow \text{epoch} + 1$;
 - <6.4> $\bar{E}^{\text{current}} \leftarrow \bar{E}(\mathbf{w})$;
- Until: $|\bar{E}^{\text{current}} - \bar{E}^{\text{previous}}| \leq \varepsilon$

End {ADALINE Algorithm – Training Phase}






بعد تطبيق الخوارزمية وإيجاد الأوزان المناسبة وإنشاء الشبكة العصبية سينتتج لدينا خط القرار وهو الذي يفصل الصنفين كما هو واضح بالشكل:



- الشكلين يوضح الخط الفاصل للأصناف وللاظه بالشكل اليميني أن الخط يتدرج من الأعلى إلى الأسفل حتى يصل للمنطقة المناسبة والأفضل
- وبالشكل اليساري فإن الخط يتدرج من الأسفل للأعلى حتى يصل لنفس المنطقة في كلتا الحالتين فإن الخط توقف في نفس المكان وبالتالي لا يهم فيما إذا كانت أصغر أو أكبر من القيمة المطلوبة وإنما المهم أن تكون قريبة منها.

دارة AND باستخدام ال ADALINE

لدينا شكل الدارة :






ولدينا جدول الحقيقة المعبر عن دارة AND

	x_0	x_1	x_2	d	
$x^{(1)}$	-1	-1	-1	-1	$d^{(1)}$
$x^{(2)}$	-1	-1	1	-1	$d^{(2)}$
$x^{(3)}$	-1	1	-1	-1	$d^{(3)}$
$x^{(4)}$	-1	1	1	1	$d^{(4)}$

سنستخدمتابع Bipolar تفعيل :



- سنستخدم قاعدة دللتا، بالبداية سنحصل على عينات التدريب والقيم المطلوبة من كل عينة وهو جدول الحقيقة
- ستقوم بربط كل عينة تدريب مع القيمة المطلوبة:

	$x^{(1)}$	$x^{(2)}$	$x^{(3)}$	$x^{(4)}$	
x_0	-1	-1	-1	-1	$d^{(1)}$
x_1	-1	-1	1	1	$d^{(2)}$
x_2	-1	1	-1	1	$d^{(3)}$

$d^{(1)}$	-1
$d^{(2)}$	-1
$d^{(3)}$	-1
$d^{(4)}$	1

- نقوم بتهيئة الأوزان بقيم عشوائية و لتكن $[1.0, 1.0, 1.0]$
- نهيئ عامل التعلم، مقدار الفرق في قيمة الخطا الناتج والذي سيعبر عن شرط التوقف، وعدد الحقبة، ولتكن بالقيم التالية:
- $\eta = 0.5, \varepsilon = 0.001, epoch = 0$
- الآن سنقوم بإنشاء حلقة وتعديل الأوزان لتصغير نسبة الخطا الناتج بقدر الإمكان، سنحسب الخطا الناتج بالبداية بالأوزان الابتدائية

$$\bar{E}(w) = \frac{1}{p} \sum_{k=1}^p (d^{(k)} - u)^2 = \frac{1}{4} \sum_{k=1}^4 (d^{(k)} - u)^2$$

$$\begin{aligned}
 u^{(1)} &= w_0 * x_0^{(1)} + w_1 * x_1^{(1)} + w_2 * x_2^{(1)} = (1.0 * (-1) + 1.0 * (-1) + 1.0 * (-1)) = -3 \\
 u^{(2)} &= w_0 * x_0^{(2)} + w_1 * x_1^{(2)} + w_2 * x_2^{(2)} = (1.0 * (-1) + 1.0 * (-1) + 1.0 * (1)) = -1 \\
 u^{(3)} &= w_0 * x_0^{(3)} + w_1 * x_1^{(3)} + w_2 * x_2^{(3)} = (1.0 * (-1) + 1.0 * (1) + 1.0 * (-1)) = -1 \\
 u^{(4)} &= w_0 * x_0^{(4)} + w_1 * x_1^{(4)} + w_2 * x_2^{(4)} = (1.0 * (-1) + 1.0 * (1) + 1.0 * (1)) = 1
 \end{aligned}$$

$$\bar{E}(w) = 0.25 \left(((-1) - (-3))^2 + ((-1) - (-1))^2 + ((-1) - (-1))^2 + ((1) - (1))^2 \right) = 1$$

وبالتالي قيمة الخطأ الحالية هي 1 وسنقوم بحساب u وبعدها تعديل الأوزان ومن ثم حساب قيمة الخطأ القديمة واختبار إذا كانت مناسبة وعندها التوقف أو مازال بالإمكان تصغيرها وحينها سنستمر بالتكرار.

الحقبة الأولى:

في كل مرة نتبع القاعدة الخاصة بتعديل الأوزان وهي:

$$w \leftarrow w + \eta \cdot (d^{(k)} - u) \cdot x^{(k)}, \quad \text{with } k = 1 \dots p$$

حيث

$$U^n = W^T \cdot X^n$$

حيث (.) تدل على ضرب المصفوفات

و بالتعويض بالقاعدة:

$$u^1 = w_0 * x_0^{(1)} + w_1 * x_1^{(1)} + w_2 * x_2^{(1)}$$

وبعد حساب u الجديدة تقوم بتعديل الأوزان

$$\bar{E}^{previous}(w) = \bar{E}(w) = 1$$

$x^{(1)}$	$u^{(1)} = w_0 * x_0^{(1)} + w_1 * x_1^{(1)} + w_2 * x_2^{(1)}$ $= (1.0 * (-1) + 1.0 * (-1) + 1.0 * (-1)) = -3$
-1	$w_0 = 1.0 + (0.5)(-1 - (-3))(-1) = 0.0$
-1	$w_1 = 1.0 + (0.5)(-1 - (-3))(-1) = 0.0$
-1	$w_2 = 1.0 + (0.5)(-1 - (-3))(-1) = 0.0$
$x^{(2)}$	$u^{(2)} = w_0 * x_0^{(2)} + w_1 * x_1^{(2)} + w_2 * x_2^{(2)}$ $= (0.0 * (-1) + 0.0 * (-1) + 0.0 * (1)) = 0$
-1	$w_0 = 0.0 + (0.5)(-1 - (0))(-1) = 0.5$
-1	$w_1 = 0.0 + (0.5)(-1 - (0))(-1) = 0.5$
1	$w_2 = 0.0 + (0.5)(-1 - (0))(1) = -0.5$
$x^{(3)}$	$u^{(3)} = w_0 * x_0^{(3)} + w_1 * x_1^{(3)} + w_2 * x_2^{(3)}$ $= (0.5 * (-1) + 0.5 * (1) + (-0.5) * (-1)) = 0.5$
-1	$w_0 = 0.5 + (0.5)(-1 - (0.5))(-1) = 1.25$
1	$w_1 = 0.5 + (0.5)(-1 - (0.5))(1) = -0.25$
-1	$w_2 = -0.5 + (0.5)(-1 - (0.5))(-1) = 0.25$
$x^{(4)}$	$u^{(4)} = w_0 * x_0^{(4)} + w_1 * x_1^{(4)} + w_2 * x_2^{(4)}$ $= (1.25 * (-1) + (-0.25) * (1) + (0.25) * (1)) = -1.25$
-1	$w_0 = 1.25 + (0.5)(1 - (-1.25))(-1) = 0.125$
1	$w_1 = -0.25 + (0.5)(1 - (-1.25))(1) = 0.875$
1	$w_2 = 0.25 + (0.5)(1 - (-1.25))(1) = 1.375$



$$w_0 = 1.0 + (0.5) - 1 - (-3)(-1) = 0.0$$

$$w_1 = 1.0 + (0.5) - 1 - (-3)(-1) = 0.0$$

$$w_2 = 1.0 + (0.5) - 1 - (-3)(-1) = 0.0$$



epoch = 1
$u^{(1)} = -2.375$
$u^{(2)} = 0.375$
$u^{(3)} = -0.625$
$u^{(4)} = 2.125$
$\bar{E}(w) = 1.29688$
$E^{current}(w) = E(w) = 1.29688$
$ \bar{E}^{current}(w) - \bar{E}^{previous}(w) = 0.296875 > \epsilon$

فقيمة الخطأ غير مقبولة وبالتالي سنستمر بتعديل الأوزان عدة دورات أخرى.
و بعد 17 حقبة تدريب سيتتج لدينا الأوزان التالية:

Number of Training Iterations	17
$W^T = [0.500042, 0.999978, 1.50002]$	

ويمكن تقريبها لتصبح:



$$W^T \approx [0.5, 1.0, 1.5]$$

وهي أوزان جيدة نستطيع بناء شبكة عصبية لدارة AND بناء عليها.

ملاحظة: التكرار لا يكون للنهاية ! وإنما بعد epoch معين وذلك لتفادي اللانهائية والتوقف عند حد معين حتى من دون الوصول للحل المطلوب، وفي هذه الحالة تكون هناك مشكلة سواء الأوزان أو القيم المطلوبة أو قيم الخطأ المتوقع والخ...

و يمكن التجرب على كود مكتوب بلغة بايثون للفهم أكثر (حاول تغيير قيم عامل التعلم والأوزان وملاحظة التغير في عدد الحقب التي احتاجها التدريب للوصول للأوزان الأفضل)، ويمكن الممارسة عليه لتعلم استخدام مكتبة numpy التي تساعدننا في تدريب العصبونات.

الكود:



رابط موقع لقراءة كود ال QR:


<https://4qrcode.com/scan-qrcode.php>

محتوى مجاني غير مخصص للبيع التجاري



الشبكات العصبية

إن هدفنا من تعلم تدريب العصبون ليس الحصول على عصبون واحد فقط، وإنما إنشاء شبكات عصبية متكاملة قادرة على القيام بمهامات صعبة ومعقدة فالعصبون هو الوحدة الأساسية للشبكة العصبية، وستتعلم بالمحاضرة القادمة كيفية إنشاء الشبكات العصبية وبناء الأساس لها ودراسة النظريات والطرق الأفضل لتدريبها واستعمالها في حل المشاكل.



The key to artificial intelligence
has always been the
representation.

- Jeff Hawkins-

The end