




7/12/2022

Resilient Back Propagation & Bayesian

د. جورج كرّاز

محتوى مجاني غير مخصص للبيع التجاري



RBO Informatics;

الشبكات العصبية

١ مقدمة:

عند اختيار شبكة عصبية أو الحديث عنها فإن أهم معيار لها هو بنيتها، فمثلاً عند الحديث عن الـ Backpropagation أو أي شيء متعلق بها، فنحن نتحدث عن بنية مكونة من طبقة دخل وطبقة خرج وبينهما طبقة بينية أو أكثر.

عملية التدريب المتعلقة بال Backpropagation تتم على مراحلتين، مرحلة Forward ومرحلة Backward.

Forward: هي عملية حساب أوتوماتيكية للخرج باستخدام الأوزان الابتدائية، وبعدها يتم مقارنة هذه القيمة مع قيمة ثابتة تدعى القيمة المرغوبة (Target)، ومن خلال الفرق يتم حساب مقدار الخطأ وبعدها مرحلة Backward: وهي عملية تغيير الخرج من خلال التعديل على الأوزان، وتستمر عملية التعديل حتى تصبح قيمة الخطأ صفر أو أقل من قيمة معينة.

في بعض خوارزميات التدريب يستمر التعديل لعدد محدد من الدورات وذلك بغض النظر عن قيمة الخطأ.

سبب ظهور خوارزمية Resilient ومبادئ عملها

خوارزمية Backpropagation هي خوارزمية مناسبة للتطبيقات التي تحتوي على Dataset صغيرة، تكون نتائجها دقيقة ولكن لاحظ العلماء تراجع أدائها في التطبيقات التي تحتوي على Dataset كبيرة بسبب الوقت الكبير الذي تحتاجه.

المشكلة الأساسية هي الحاجة لذاكرة كبيرة لعمليات الحساب، لأنها تقوم بحساب ال derivation وتقوم بحسابات كبيرة على مستوى vector وليس على مستوى element واحد، وبالتالي عند تحديث الأوزان فإننا نحدث على مستوى Vector من الأوزان وليس على مستوى وزن واحد. ومن هنا جاءت فكرة خوارزمية Resilient Back propagation (RBP) حيث اقترح العلماء أن يكون التحديث على مستوى وزن واحد.



مبدأ عملها مشابه لخوارزمية Backpropagation بشكل عام ولكن هنا على مستوى وزن واحد، حيث نستبدل عملية حساب ال derivation لكل وزن (وهي عملية تستغرق وقتاً) بإضافة معامل η (إيتا) يتم عن طريقه حساب تغير الوزن ΔW_{ij} .

ملاحظة: اصطلاحاً وحسب المراجع تعتبر التالي:

- i is index of a neuron in the input layer.
- j is index of a neuron in hidden layer.
- k is index of a neuron in the output layer.

تابع التفعيل:

تستخدم خوارزمية RBP تابع sigmoid وهو من الشكل:



$$F(x) = \frac{1}{1 + e^{-x}}$$

تم اختيار هذا التابع لسببين:

- ✓ **السبب الأول:** خرج التابع 0 أو 1 أو بينهما، وبالتالي التابع مناسب لعملية التصنيف (classification).
- ✓ **السبب الثاني:** تابع sigmoid داخل خوارزمية تدريب ال BP حيث أنه عند القيام بتحديث الأوزان نأخذ مشتق تابع التفعيل وهو sigmoid.

Learning Algorithm:

- عند تمثيل علاقة الخطأ (وهو من الدرجة الثانية) بدلالة الأوزان نحصل على قطع مكافئ تقعره نحو الأسفل وعلى أجزاء هذا القطع نختار قيمة w ، وتكون ال local minimum في أسفل هذا القطع.
- سابقاً عند القيام بعملية التدريب بال BP عند معادلة تعديل الأوزان قمنا بإضافة إشارة ناقص ومعناها عند تجاوز نقطة ال local minimum وميل المماس موجب يجب أن ننقص القيمة، والعكس صحيح عندما يكون ميل المماس سالب يجب أن نزيد القيمة.
- لكن في حالتنا الآن خوارزمية RBP تعتبر مرنة، أي أنه يجب علينا اكتشاف الإشارة من خلال تغيير إشارة المشتق والذي تتغير قيمته عند كل تحديث للوزن، وهناك ثلاث حالات سنقوم بإضافة قيمة مختلفة لها حسب الحالة، حيث نفترض قيمة ناقص ل إيتا، وقيمة زائد ل إيتا.
- إيتا كمعامل لها قيمة ثابتة حسب التجارب سواء بالناقص أو الزائد.
- بالنسبة للزائد قيمتها أكبر من واحد.
- بالنسبة للناقص قيمتها بين صفر وواحد.
- ولكن اعتماداً على العلماء ومن خلال التجرب تم اعتماد قيمة إيتا زائد (η^+) ب 1.2 و قيمة إيتا ناقص (η^-) ب 0.5.



الحالات الثلاث التي تحدثنا عنها في الفقرة السابقة:

1. المشتق أكبر من الصفر (الوزن الحالي على يمين الوزن المثالي أي أكبر منه) \Rightarrow يجب أن نقوم بإنقاص الوزن بقيمة دلتا تابعة لقيمة إيتا الكبيرة (η^+) وذلك بعد إعطائهما إشارة ناقص.
2. المشتق أصغر من الصفر (الوزن الناتج على يسار الوزن المثالي أي أصغر منه) \Rightarrow يجب أن نقوم بزيادة الوزن بقيمة دلتا تابعة لقيمة إيتا الصغيرة (η^-) وذلك بعد إعطائهما إشارة ناقص.
3. المشتق صفر \Rightarrow لا نضيف شيء.

التمثيل الرياضي للخوارزمية:

في البداية سنقوم بتمثيل الحالات الثلاث المعبرة عن تعديل الأوزان:

$$\Delta_{ij}(t) =$$

1. $\eta^+ \cdot \Delta_{ij}(t-1)$ if $\frac{\partial E}{\partial W_{ij}}(t) \cdot \frac{\partial E}{\partial W_{ij}}(t-1) > 0$
2. $\eta^- \cdot \Delta_{ij}(t-1)$ if $\frac{\partial E}{\partial W_{ij}}(t) \cdot \frac{\partial E}{\partial W_{ij}}(t-1) < 0$
3. $\Delta_{ij}(t-1)$



نستطيع كتابة المعادلات على الشكل التالي ونحسب قيمة Δ :

$$\Delta_{ij}(t) =$$

$$-\Delta_{ij}(t) \text{ if } \frac{\partial E}{\partial W_{ij}} > 0$$

$$\Delta_{ij}(t-1) \text{ if } \frac{\partial E}{\partial W_{ij}} < 0$$

$$\text{else } 0$$

عملية الزيادة والنقصان على الوزن تتم حسب المعادلة:

$$W_{ij}(t+1) = W_{ij}(t) + \Delta W_{ij}(t)$$

مع كل دورة حساب نقوم بتطبيق التدرج على قيمة W_{ij} ومراقبة قيمتها وبناءً عليها نزيد أو ننقص قيمة W .

$$\Delta W_{ij}(t) = -W_{ij}(t-1)$$

$$\text{if } \frac{\partial E}{\partial W_{ij}}(t) \cdot \frac{\partial E}{\partial W_{ij}}(t-1) < 0$$

بالنهاية نقوم بحساب قيمة الخطأ لدورة التدريب كاملة ونقوم بمقارنة القيمة ونرى إذا وصلنا لل local minimum .

Evaluation:


عملية ال Evaluation لهذه الخوارزمية تشبه عملية Evaluation في باقي الخوارزميات حيث تتم أثناء ال training stage وذلك من خلال حساب الخطأ ومشاهدة تناقص قيمته أثناء الدورات (epochs)، وذلك حتى الوصول إلى الهدف.



عملية تقسيم Data set

أثناء التدريب لكل الشبكات العصبية نحن بحاجة لتحديد الـ *test data* و *validation data*.
أي عندما يكون لدينا *Data set* ونريد أن نبني عليها نظام ذكي أو شبكة عصبية، فإن أول خطوة يجب أن نفكر فيها هي تطبيق *segmentation* على الداتا بين *training data* و *testing data*.

عادة النظريات تقول أن النسبة يجب أن تكون 40% *testing* و 60% *training*.
ولكن هذا لا يكفي حيث يجب أن تكون الحالات المصنفة موزعة طبيعياً ضمن المجموعات، حيث يجبأخذ نسبة متساوية من العينات في التدريب والاختبار سواء كانت حالات سلبية أو إيجابية.
مثال: ليكن لدينا 1000 حالة اختبار، التوزيع يجب أن يكون كالتالي:



أو ما يقارب ذلك (nearly normal distributed).

عملية الـ validation

نقوم بعملية إدخال جديدة لدادا دخلت إلى التدريب سابقاً ونراقب السلوك، يكون السلوك جيداً عندما يكون مسيراً لقيمة الخطأ أثناء التدريب.

عملية الـ testing

نقوم بإدخال دادا جديدة كلها ونراقب سلوكه، وللحصول على نتائج جيدة يجب أن يكون السلوك متتشابه أثناء الـ *learning* والـ *validation* والـ *testing*.

Bayesian

مبدأ الـ Bayesian هو مبدأ احتمالي وهو عكس الاحتمال الشرطي.



تذكرة: الاحتمال الشرطي: هو احتمال وقوع حدث علمًا أن حدث آخر قد وقع. ■

أي إننا نعرف أن الأحداث الأخرى قد وقعت ولكننا نريد أن نعرف احتمالية هذا الحدث.

(الانحدار اللوجستي): Logistic Regression

وهو عبارة عن تمثيل رياضي لمشكلة موجودة تصنف بشكل باينري (أبيض أو أسود)، تمثلها يتم عن طريق الـ *Logistic Regression*.

مثال: عند تشخيص مرض ورم ← سليم أو مصاب.




تابع التنشيط:

تابع التنشيط المستخدم هو sigmoid.

فائدة: نستخدم الـ Logistic Regression مع Bayesian بالتشخيص الطبي.

حيث يقوم التابع بأخذ فرضية (Hypothesis), ممكن تكون خطية وممكن أن تكون غير خطية، والتي تمثل h_{θ} .


عندما تكون الفرضية خطية تكون من الشكل:



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

ونستطيع الفصل بينهما خطياً.

عندما تكون الفرضية غير خطية يكون أيضاً عن طريقأخذ sigmoid لهذه الفرضية:





$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

Cost function:

عند القيام بدراسة نجد أن Cost function تكون من جزئين رياضيين، وكل منهما تمثل:

$$\text{cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$



. $y = 0$ هو مجموع للدين أي الحد الأول عندما $y = 1$ والحد الثاني عندما $y = 0$ في Cost function

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{cost}(h_{\theta}(x^{(i)}), y^{(i)}) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

والآن نريد تصغير تابع ال cost وذلك عن طريق المشتق بكل دورة والتعديل على الأوزان.

$$\text{Repeat} \{$$

$$\theta_j = \theta_j - \alpha \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$\}$$

Testing Stage Evaluation

تحدثنا سابقاً عن عملية ال Evaluation والتي تتم خلال مرحلة ال training من خلال مراقبة قيمة الخطأ أو من خلال ال validation .

والآن سوف نتحدث عن ال testing، حيث سوف نقوم بمقارنة الخرج مع القيم المرغوبة وذلك عن طريق confusion matrix على عدة حالات:

1. TP: أي الحالات الصحيحة الموجبة.

2. TN: أي الحالات الصحيحة السالبة.

3. FP: أي الحالات الخاطئة الموجبة.

4. FN: أي الحالات الخاطئة السالبة.





حيث: $CN = Tp + Fn$ وهي الحالات الموجبة الكلية.
 . وهي الحالات السالبة الكلية.

مثال:

c_n	c_p	T_p	T_n	F_p	F_n
10000	9000	8100	9000	1000	900

بناءً على ال confusion matrix هناك أربع عوامل إحصائية تعكس ال Evaluation أثناء عملية ال testing . 1. Sensitivity (se): تمثل قدرة النظام على كشف الحالات الإيجابية بشكل صحيح.

$$se = \frac{T_p}{C_p}$$

2. Specificity (sp): تمثل قدرة النظام على كشف الحالات السلبية بشكل صحيح.

$$sp = \frac{T_n}{C_n}$$

3. Accuracy (Acc): تمثل قدرة النظام على كشف الحالات الصحيحة بشكل عام.

$$Acc = \frac{(T_n + T_p)}{(C_n + C_p)}$$

4. Testing Error (Err): ويمثل مقدار الخطأ.

يعطى بأحد العلقتين:

$$1. Err = 1 - Acc$$

$$2. Err = \frac{(F_n + F_p)}{(C_n + C_p)}$$

ويمثل الجدول التالي القيم الإحصائية للجدول السابق الذي مرّ معنا:


c_n	c_p	S_e	S_p	Acc	Err
10000	9000	90%	90%	90%	10%

Receiver Operating Characteristics (ROC) Curve

يعد أحد أهم الميثودولوجي الأساسية المستخدمة في تقييم أنظمة الذكاء الصنعي.
 يمثل العلاقة بين احتمالية الحالات الموجبة الصحيحة واحتمالية الحالات الموجبة الخاطئة.


يعطى بالعلاقة:

$$\frac{F_p}{C_n} = \frac{F_p}{(F_p + T_n)} = 1 - S_p$$



من أجل الرسم البياني نحتاج إلى أربعة عبارات مختلفة أو أكثر:

Threshold	$S_e \%$	$1 - S_e \%$
0.1	0.7	0.25
0.2	0.85	0.2
0.5	0.9	0.1
0.5	0.95	0.08



المساحة الموجودة تحت منحنى ROC هي عامل مهم جداً لأداء المصنف، ويتم حسابها من خلال متوسط الدسسيات.

انتهت المحاضرة

